Fuzzy Cognitive Diagnosis: Reproduction of the MFCD Core and a Controlled Evaluation of Its Fuzzy Extensions

Musa Semih Büyüközkan (1306230099)

Bulanık Mantık Dersi, Dönem Projesi, 2026-2027 Güz

Kod ve veri betikleri: github.com/semihbuyukozkan/fuzzy-cognitive-diagnosis

Özet (Abstract). Bu çalışma, Zhang ve Wang'ın (2025) bulanık bilişsel tanı modelinin (MFCD) bulanık mantık çekirdeğini yeniden gerçekleştirir: sigmoid üyelik fonksiyonu, objektif sorularda bulanık VE (t-norm), subjektif sorularda bulanık VEYA (t-conorm), bilgi açığı, slip/guess ve Metropolis-Hastings (MH) ile parametre kestirimi. Makalenin dikkat tabanlı bileşeni (MAKT) kapsam dışıdır. Çekirdek, kamuya açık FrcSub verisinde IRT-2PL, DINA ve FuzzyCDF-orig ile 10 seed üzerinden karşılaştırılmıştır. Özgün katkı iki kontrollü deneydir: (K1) bulanık operatör ailelerinin karşılaştırılması, (K2) makalenin zaman, süre ve bilgi açığı eklemelerinin sentetik veride ablation'ı ve bir negatif kontrol. Sonuçlar: MFCD-core, FuzzyCDF-orig'i geçmedi (F1 farkı yaklaşık -0.003); operatör seçimi gerçek veride etkisiz; K2'de görülen F1 artışı (+0.053) kalibrasyon kaymasından kaynaklanan bir yapaylık olarak çıktı: eşikten bağımsız AUC hiçbir faktörle artmadı ve negatif kontrolde de aynı F1 artışı görüldü. Makalenin iddiası bizim koşullarımızda yeniden üretilemedi; bu, makalenin yanlış olduğu anlamına gelmez, çünkü çalışmamız MAKT'ı, makalenin kapalı verisini ve belirsiz bırakılmış ağırlık uygulamalarını içermemektedir.

1. Introduction

Problem. Bir öğrencinin henüz çözmediği bir alıştırmadaki başarısını, geçmiş cevaplarından tahmin etmek eğitimde kişiselleştirilmiş öneri sistemlerinin temel adımıdır. Klasik tanı modelleri (DINA gibi) bir beceriyi "var/yok" diye ikili ele alır; oysa öğrencinin bir beceriye sahip olma durumu kısmidir. Bulanık kümeler [9] bu kısmi sahipliği 0 ile 1 arasında bir *üyelik derecesi* ile ifade eder. FuzzyCDF [2], [3] bu fikri bilişsel tanıya taşımıştır.

Referans makale. Zhang ve Wang [1], FuzzyCDF'yi üç eklemeyle genişletir: cevabın kaydedilme zamanına göre ağırlık, cevap süresine göre ağırlık ve bilgi açığı (becerinin bir soru için derecelendirilmiş önemi). Bunu çok başlı dikkat mekanizmalı (MAKT) bir derin ağla birleştirir.

Amaç ve kapsam. Dönem projesi için yeniden gerçekleştirme kapsamı (MRR) şöyle belirlendi: makalenin *bulanık mantık çekirdeği* (MFCD-core) uygulanır; MAKT uygulanmaz. Kod tamamen bu projede yazılmıştır, makale yazarlarının resmi kodu kullanılmamıştır. Çalışmanın üç katkısı vardır: (i) çekirdeğin FrcSub üzerinde baseline'larla karşılaştırması ve makale eğilimleriyle kıyası; (ii) MCMC yakınsama kanıtı; (iii) iki özgün kontrollü deney (K1, K2). Çalışma boyunca ilke şuydu: hiçbir sayı elle yazılmaz, rapordaki her tablo `results/tables` altındaki betik çıktılarından üretilir.

2. Related Work

Bilişsel tanı modelleri, öğrencinin gizli becerilerini soru-beceri (Q) matrisi aracılığıyla cevaplarla ilişkilendirir. DINA [4] bağlayıcı (conjunctive) ikili modeldir: soruyu çözmek için gereken tüm becerilere sahip olmak gerekir, slip ve guess parametreleri gürültüyü karşılar. FuzzyCDF [2], [3] becerileri bulanıklaştırır ve hem objektif hem subjektif soruları (kısmi puan) aynı çatıda modeller. Derin öğrenme tabanlı yaklaşımlar iki hat izler: bilgi izleme (knowledge tracing) modelleri DKT [5] ve DKVMN [6] öğrencinin zamansal gelişimini yakalar; NeuralCDM [7] ise etkileşim fonksiyonunu sinir ağıyla öğrenir ve Q matrisini kullanır. Bu hatların kapsamlı bir derlemesi [8]'de (ön baskı) bulunur. Bulanık tabanlı modeller yorumlanabilirlik, derin modeller ise tahmin gücü sunma eğilimindedir; Zhang ve Wang [1] ikisini birleştirmeyi önerir. Bizim katkımız yeni bir model önermek değil, makalenin bulanık eklemelerinin etkisini kontrollü deneylerle ayrıştırmaktır.

3. Theoretical Background

Bulanık küme ve üyelik fonksiyonu. Klasik kümede bir eleman ya vardır ya yoktur; bulanık kümede eleman bir *üyelik derecesi* $\mu \in [0,1]$ ile kümeye aittir [9]. Bu çalışmada "beceri k'yı bilenler" bulanık kümesinin üyelik derecesi öğrencinin o beceri için yeterliliğidir. Üyelik fonksiyonu sigmoiddir (fuzzification adımı):

$$a_{ik} = 1 / (1 + exp(-1.7 \cdot \alpha_k \cdot (\theta_i - \beta_k))) \quad (1)$$

Burada θ_i öğrencinin gizli yetenek düzeyi, α_k becerinin ayırt ediciliği, β_k zorluğudur. Dilsel değişken (linguistic variable) kullanılmaz; "düşük/orta/yüksek" gibi etiketler yerine sürekli derece kullanılır.

t-norm ve t-conorm. Bulanık VE (kesişim) t-norm, bulanık VEYA (birleşim) t-conorm ile hesaplanır. Üç aile karşılaştırılır: Gödel (min / max), çarpım (a·b / a+b−ab) ve Łukasiewicz (max(0,a+b−1) / min(1,a+b)). Objektif sorularda tüm gerekli beceriler gerektiği için VE, subjektif sorularda bir beceri diğerini telafi edebildiği için VEYA kullanılır.

Bilgi açığı. Becerinin soru için önemi $\mu_{jk} \in [0,1]$ ile derecelendirilir. Objektif soruda katkı $\tilde{a} = 1 - \mu(1 - a)$ (eksik bilgi "açığı" önemiyle cezalandırılır), subjektif soruda $\tilde{a} = \mu \cdot a$. Gödel VE ile birleşince $\eta = 1 - \max_k \mu_{jk}(1 - a_{ik})$ elde edilir (makalenin Eş. 8-9'u). μ ikili Q'ya eşitse bu ifade tam olarak $\min_k a_{ik}$'ye iner; bu eşdeğerlik rastgele girdilerle sayısal olarak test edilmiştir.

Slip/guess ve karar. $P(r=1) = (1-s)\cdot\eta + g\cdot(1-\eta)$. P her zaman [g, 1−s] aralığında kaldığı için log(0) oluşmaz. Çıktı bir olasılıktır; 0.5 eşiği ile kesin "doğru/yanlış" kararına çevrilir. Bu eşikleme, klasik Mamdani sistemlerindeki *durulaştırma* (defuzzification) adımının bu problemdeki karşılığıdır. Sistem Mamdani veya Sugeno tipi bir kural tabanlı çıkarım değildir; "kural tabanı", Q matrisinin tanımladığı "gereken tüm becerilere sahipse" (VE) / "herhangi birine sahipse" (VEYA) kurallarıdır. Type-2 bulanık mantık, ANFIS veya Fuzzy C-Means kullanılmamıştır.

4. Original Method

Makalenin yöntemi iki katmandır. **MFCD** katmanı, Eş. (1) üyeliklerini zaman ağırlığı $\omega_{time} = (T_m - \Delta t)/T_m$ (eski kayıt daha az ağırlıklı), cevap süresi ağırlığı (hızlı doğru cevap daha güvenilir) ve bilgi açığı ile birleştirerek her soru için η üretir; slip/guess ile cevap olasılığına çevirir; parametreler MH ile kestirilir. **MAKT** katmanı, BiGRU ve çok başlı dikkat ile zaman içindeki bilgi durumunu izler. Makale, kapalı bir İngilizce egzersiz verisinde 1000 öğrenci, 50 soru (38 okuma, 6 yazma, 6 çeviri) ve 25 bilgi noktası ile çalışır; DINA, FuzzyCDF, My-FuzzyCDF, DKT ve C&RM-MAKT ile PRE, Recall, F1, MAE ve RMSE üzerinden karşılaştırır. Makalenin Tablo 4'ünde MFCD-MAKT her ölçütte en iyi görünür (ör. nesnel sorularda %60 eğitimde F1 = 0.726).

Eleştirel değerlendirme. Güçlü yön: üç bulanık eklemenin sezgisel gerekçesi açıktır ve öznel soruları da kapsar. Sınırlılıklar: (i) veri kapalıdır, sonuçlar bağımsız doğrulanamaz; (ii) zaman ağırlığının Eş. 3'te yeterlilikle *çarpılması* ile olabilirlik ağırlığı olması arasında belirsizlik vardır, süre ağırlığının (Eş. 7) nerede kullanıldığı yazılı değildir; (iii) Tablo 4'te metin "her tipte ve oranda en iyi" derken subjektif %50 Recall'da C&RM-MAKT (0.532) MFCD-MAKT'tan (0.525) yüksektir; (iv) PRE ve Recall'dan hesaplanan F1 tablodaki F1 ile tutmaz (ör. nesnel %60 MFCD-MAKT: PRE 0.894, Recall 0.631 için ≈0.74, tabloda 0.726); (v) FuzzyCDF'nin nesnel F1 değeri %60'tan %70'e düşer (0.557 → 0.537); (vi) MAKT'ın katkısı bulanık eklemelerin katkısından ayrıştırılmamıştır. Kurduğumuz ablation tam olarak bu son noktayı sınar. Makale sayıları `docs/paper_reference_results.md` dosyasında aktarılmıştır.

5. Reproduction Methodology



Şekil 1. Gerçekleştirilen bulanık sistem akışı (src/memberships.py, src/fuzzy_ops.py, src/mfcd.py).

MFCD-core. Şekil 1'deki akış vektörel olarak uygulanmıştır. Parametreler (θ, α, β, s, g ve isteğe bağlı μ) random-walk Metropolis-Hastings [10] ile kestirilir. Önseller bizim seçimimizdir: θ, $\beta \sim N(0,1)$; $\log \alpha \sim N(0, 0.5^2)$; s, g $\sim$ U(0, 0.4); $\mu \sim U(0,1]$. Zincir 1500 adım (700 burn-in) ve her 10. örnek saklanır; tahmin, posterior ortalama olasılıktır. Adım boyları kabul oranı 0.25-0.55 olacak biçimde elle ayarlanmıştır.

Ağırlıklar ve varsayımlarımız. Zaman ve süre ağırlıkları, gözlemin olabilirliğe katkısını çarpan *olabilirlik ağırlıkları* olarak uygulanmıştır: $w = \omega_{time} \cdot (1 + \lambda \cdot \omega C)$, $\lambda = 1$, $\omega C = (\max C_j - C_{ij})/\max C_j \cdot R_{ij}$. Bu normalizasyon ve λ bizim yorumumuzdur. Makalenin Eş. 3'ündeki gibi yeterliliği VE/VEYA'dan önce ω ile çarpan yazım da ayrı bir ayar olarak ("Eş.3 çarpımı") uygulanmıştır. Makale ağırlık uygulamasını belirsiz bıraktığı için bu iki uygulama makalenin gerçek yönteminin kanıtı değil, bizim iki okumamızdır.

Baseline'lar. *IRT-2PL*: MAP ile (L-BFGS, analitik gradyan `check_grad` ile doğrulanmış). *DINA*: Gibbs örnekleyici (K = 25 için EM pratik değildir); makaledeki higher-order DINA ile birebir aynı olmayabilir. *FuzzyCDF-orig*: MFCD çekirdeği, $\mu = Q$ (açık kapalı), min/max, ağırlıksız. *MFCD-core*: FuzzyCDF-orig'e ek olarak dereceli μ öğrenir.

Yakınsama. Seçilen yöntem, aynı veride 4 zincirden split R-hat [11], burn-in sonrası log-olabilirlik sürüklenme ölçüsü ve dağınık başlangıçlardır (Bölüm 8.2). Doğrulama: 68 birim testi (elle hesaplı t-norm/t-conorm değerleri, min indirgeme, Łukasiewicz uç değerleri, metrikler, veri boyutları) geçmektedir.

6. Proposed Extension

Motivasyon. Makale üç bulanık ekleme ile derin bir bileşeni aynı anda önerir ve katkılarını ayrıştırmaz. Bu yüzden iki kontrollü deney tasarlandı.

K1 (ana katkı): operatör karşılaştırması. Model sıfırdan, aynı seed, aynı eğitim/test bölmesi ve aynı hiperparametreyle eğitilir; yalnızca t-norm/t-conorm ailesi değişir ($\mu = Q$, zaman/süre kapalı). FrcSub'da yalnızca VE; sentetik veride hem VE hem VEYA. Fark, aynı seed'deki Gödel koşusuna göre *eşleştirilmiş* hesaplanır.

K2: faktör ablation'ı ve negatif kontrol. Yalnızca sentetik veri (FrcSub'da zaman, süre ve öznel soru yoktur): "hiçbiri", +bilgi açığı, +zaman (olabilirlik), +zaman (Eş.3 çarpımı), +bilgi açığı +zaman, +süre, hepsi; ayrıca IRT-2PL ve DINA. **Negatif kontrol**: aynı veri, ancak zaman ve süre cevaptan bağımsız üretilmiş (kayma yok, süre gürültü). Bu varyantta bir faktör yine de iyileşme gösteriyorsa, iyileşme faktörün bilgisinden değil yöntemin bir yan etkisinden gelir.

Ek ölçütler. PRE, Recall, F1 (doğru = pozitif, eşik 0.5), MAE, RMSE'ye ek olarak eşikten bağımsız AUC ve kalibrasyon (ortalama tahmin − gerçek doğru oranı) raporlanmıştır. Bu ek ölçütler, ilk K2 sonuçlarında F1 artışının şüpheli görünmesi üzerine eklenmiştir; ilk koşu ile tekrar koşu F1/RMSE'de birebir aynıdır.

7. Experimental Setup

FrcSub [2]: kesir çıkarma testi, 536 öğrenci × 20 soru, 8 beceri, ikili cevap, yalnızca objektif; zaman/süre yoktur. Kaynak http://staff.ustc.edu.cn/~qiliuql/data/math2015.rar, SHA-256 doğrulaması ve boyut doğrulaması kodda yapılır; ham veri repoya konmaz. **Sentetik veri (açıkça sentetik)**: 1000 öğrenci, 50 soru (38 okuma, 6 yazma, 6 çeviri), 25 beceri, dereceli $\mu \in (0.5, 1]$, Gödel çıkarımıyla üretilmiş, $\Delta t \sim U(0,180)$ gün, yetenek kayması 0.6, süre zaman/yetkinlikle ilişkili (etkili varyant). Veri bu faktörlerle üretildiği için onları modelleyen yöntem avantajlıdır (döngüsellik); sonuçlar "geri kazanılabilirlik" gösterir, gerçek dünya yararını kanıtlamaz.

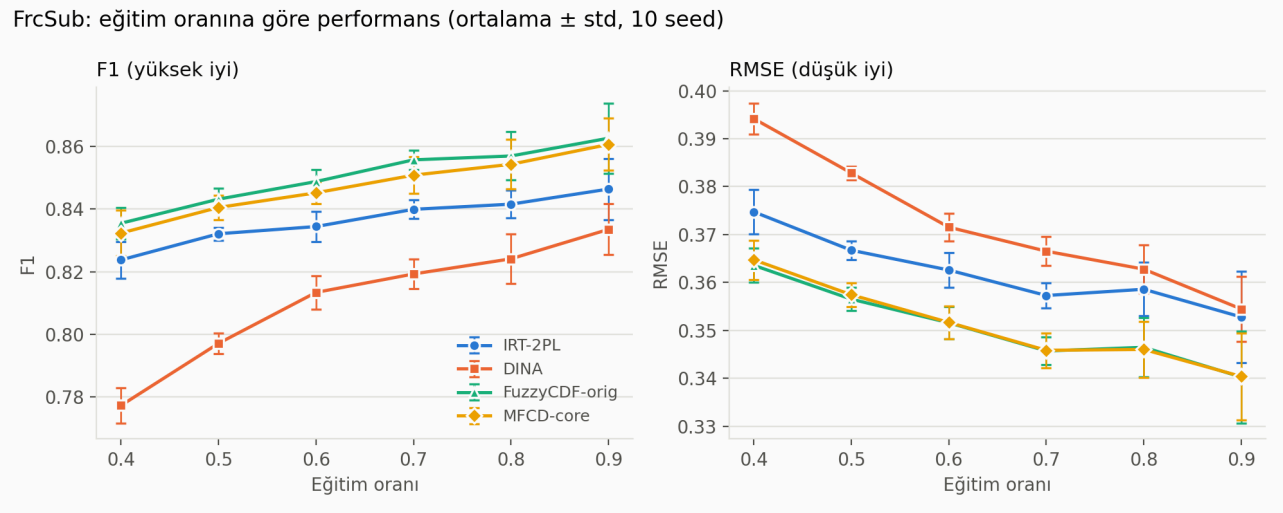
Protokol. Her öğrencinin cevaplarının %40-90'ı eğitim, kalanı test; seed 0-9, her model için aynı bölme. E1'de oranlar 0.4-0.9 (raporda 0.5/0.6/0.7), K1 FrcSub'da 0.5/0.6/0.7, K1/K2 sentetikte (çarpım verisi dahil) yalnızca 0.6. MH modelleri FrcSub'da 3 farklı başlangıçla koşulur ve *eğitim* olabilirliği en yüksek zincir seçilir (test verisine bakılmaz). **Ortam:** Apple M4 Pro, Python 3.10.11, numpy 1.26.4, scipy 1.11.4, pandas 2.1.4, matplotlib 3.8.4 (requirements.txt). Süre ölçümü ayrı, tek işlemli ve tek zincirli bir koşuyla yapılmıştır (E4); deney koşuları 10 işlemde paralel çalıştığı için o koşulardaki süre sütunları kıyaslanmaz.

8. Results

8.1 E1: FrcSub üzerinde yeniden gerçekleştirme (10 seed, ortalama ± std)

Eğitim	Model	PRE	Recall	F1	MAE	RMSE
%50	IRT-2PL	0.814 ± 0.006	0.852 ± 0.007	0.832 ± 0.002	0.242 ± 0.001	0.367 ± 0.002
%50	DINA	0.844 ± 0.005	0.755 ± 0.004	0.797 ± 0.003	0.302 ± 0.002	0.383 ± 0.001
%50	FuzzyCDF-orig	0.819 ± 0.005	0.869 ± 0.005	0.843 ± 0.003	0.259 ± 0.002	0.357 ± 0.002
%50	MFCD-core	0.823 ± 0.006	0.859 ± 0.006	0.841 ± 0.004	0.264 ± 0.002	0.357 ± 0.003
%60	IRT-2PL	0.815 ± 0.007	0.855 ± 0.006	0.834 ± 0.005	0.241 ± 0.002	0.363 ± 0.004
%60	DINA	0.850 ± 0.006	0.780 ± 0.010	0.813 ± 0.005	0.284 ± 0.003	0.372 ± 0.003
%60	FuzzyCDF-orig	0.823 ± 0.005	0.877 ± 0.007	0.849 ± 0.004	0.252 ± 0.002	0.352 ± 0.003
%60	MFCD-core	0.828 ± 0.005	0.864 ± 0.007	0.845 ± 0.004	0.254 ± 0.002	0.352 ± 0.003
%70	IRT-2PL	0.816 ± 0.006	0.865 ± 0.007	0.840 ± 0.003	0.238 ± 0.002	0.357 ± 0.003
%70	DINA	0.845 ± 0.005	0.795 ± 0.009	0.819 ± 0.005	0.272 ± 0.002	0.367 ± 0.003
%70	FuzzyCDF-orig	0.827 ± 0.005	0.887 ± 0.006	0.856 ± 0.003	0.245 ± 0.001	0.346 ± 0.003
%70	MFCD-core	0.830 ± 0.008	0.873 ± 0.010	0.851 ± 0.006	0.247 ± 0.002	0.346 ± 0.004

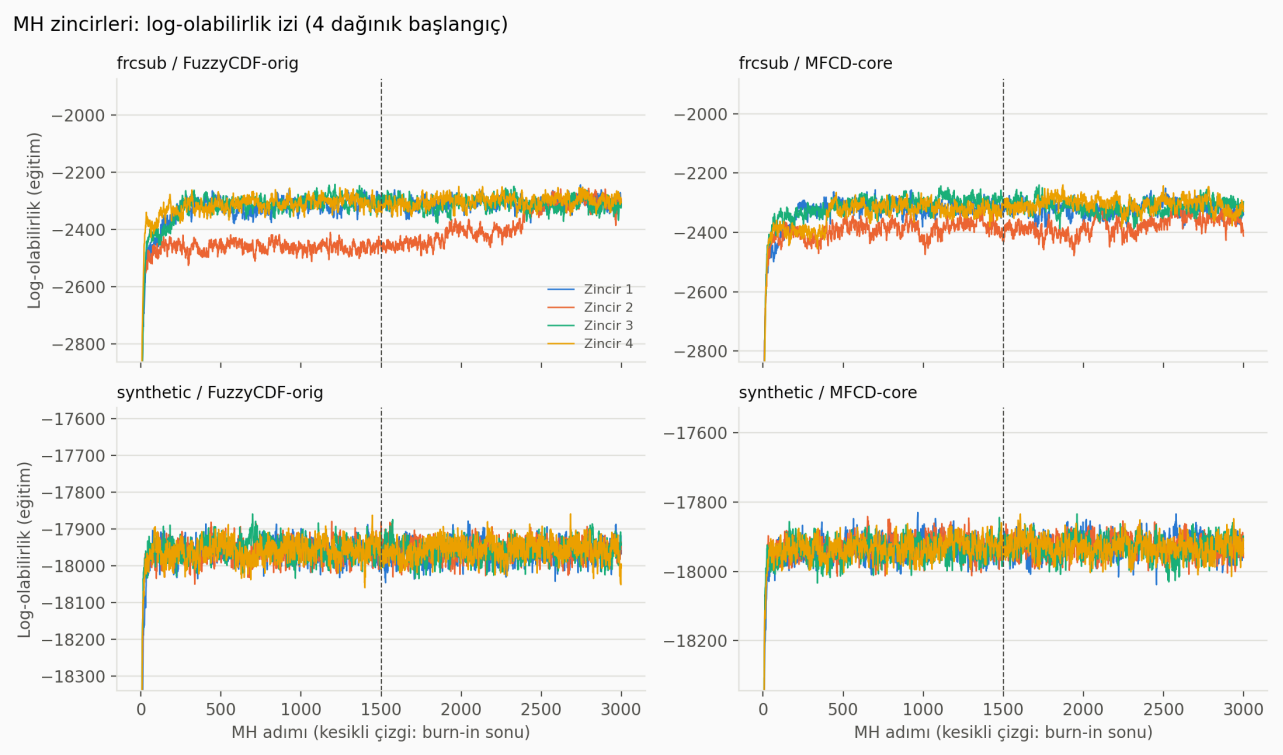
Tablo 1. FrcSub sonuçları. PRE/Recall/F1: doğru cevap pozitif sınıf. Kaynak: results/tables/e1_frcsub_summary.csv.



Şekil 2. Eğitim oranına göre F1 ve RMSE (40%-90%, ortalama ± std).

Makale Tablo 4'ü ile eğilim karşılaştırması (mutlak sayılar veri ve protokol farkı nedeniyle kıyaslanmaz): **(uyuşan)** eğitim oranı arttıkça tüm modellerde iyileşme; DINA < FuzzyCDF (F1: bizde 0.813 < 0.849, makalede 0.461 < 0.557, %60). **(uyuşmayan)** Makalede DINA'nın PRE'si en düşüktür, bizde en yüksektir (0.850); MFCD-core, FuzzyCDF-orig'i geçmez (F1 −0.003 ... −0.005, RMSE aynı); makaledeki sıralama FuzzyCDF < My-FuzzyCDF < MFCD-MAKT bizde yeniden üretilemedi. **(test edilemeyen)** Subjektif < objektif başarı, çünkü FrcSub'da subjektif soru yoktur. Olası nedenler: FrcSub'da zaman/süre bilgisi yoktur (üç eklemenin ikisi devre dışı); Q ikili olduğu için bilgi açığı zaten min'e iner, öğrenilen μ ek serbestlik ama ek bilgi değildir; makalenin büyük sıçraması MAKT'tan geliyor olabilir (kapsam dışı); μ öğrenmek çok modlu bir posterior doğurur. Makalenin kendi Tablo 4'ünde My-FuzzyCDF − FuzzyCDF F1 farkı nesnelde küçük (+0.069/+0.016/+0.024), öznelde büyüktür (+0.199/+0.140/+0.108); FrcSub öznel soru içermediği için bu etki burada ölçülemez.

8.2 MCMC yakınsama kanıtı



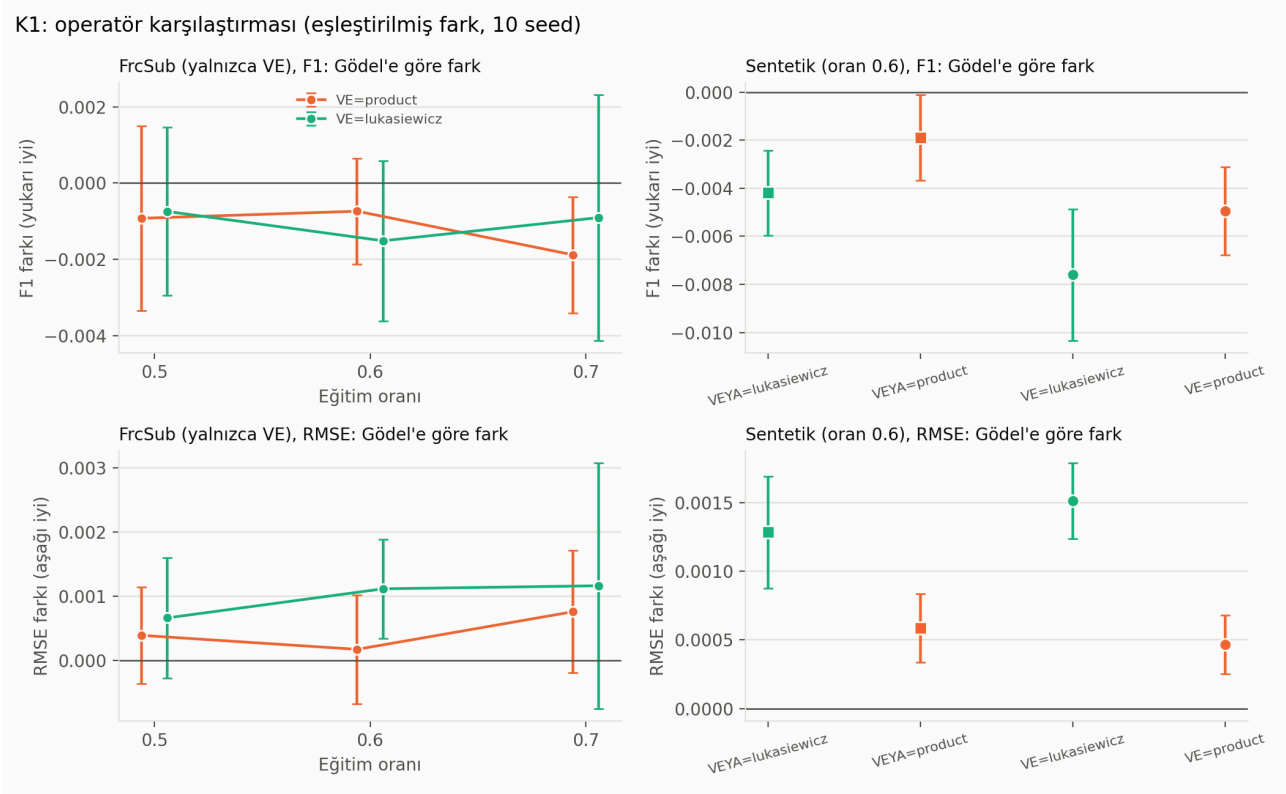
Şekil 3. Dört zincirin log-olabilirlik iz grafiği (kaynak: mcmc_convergence.py).

Sentetik veri: tahmin açısından yakınsama vardır: log-olabilirlik R-hat 1.000-1.010, θ için en fazla 1.027, dört zincirin test F1 değerleri arasındaki fark ≤ 0.002. Buna karşılık bireysel α, β, slip, guess ve özellikle μ için çok sayıda R-hat > 1.1 vardır (MFCD-core, dağınık başlangıç: μ için 129 parametrenin 60'ı). Bu parametreler zayıf belirlenmiştir: **tahmin güvenilir, bireysel parametre değerleri yorumlanamaz. FrcSub:** gerçek bir sorun vardır. Dağınık başlangıçta log-olabilirlik R-hat 2.04 (FuzzyCDF-orig) ve 1.68 (MFCD-core); bir zincir uzun süre kötü bir platoda kalır. Çözüm olarak FrcSub'da 3 başlangıç ve en yüksek *eğitim* olabilirliği seçimi kullanıldı. E1'in 120 MH koşusundan 44'ünde (MFCD-core 39/60, FuzzyCDF-orig 5/60) üç başlangıcın eğitim log-olabilirlik ortalamaları arasındaki fark 30'dan büyüktür; yani MFCD-core başlangıca duyarlıdır ve 3 başlangıç bunu azaltır ama garanti etmez. İlk tek zincirli E1'de MFCD-core haksız yere kötü çıkmıştı (F1 farkı −0.008); düzeltmeden sonra yaklaşık −0.003. Sürüklenme ölçüsü yatay giden bir zinciri yakalamadığı için yardımcı bir göstergedir; asıl kanıt R-hat ve zincirler arası düzey farkıdır.

8.3 K1: operatör karşılaştırması

Veri	Ayar	F1	RMSE
FrcSub (%60)	VE=godel	0.849 ± 0.004	0.352 ± 0.003
FrcSub (%60)	VE=lukasiewicz	0.847 ± 0.004	0.353 ± 0.004
FrcSub (%60)	VE=product	0.848 ± 0.004	0.352 ± 0.004
Sentetik (%60)	VE=godel / VEYA=godel	0.618 ± 0.037	0.465 ± 0.006
Sentetik (%60)	VE=godel / VEYA=lukasiewicz	0.614 ± 0.037	0.467 ± 0.006
Sentetik (%60)	VE=godel / VEYA=product	0.616 ± 0.037	0.466 ± 0.006
Sentetik (%60)	VE=lukasiewicz / VEYA=godel	0.610 ± 0.038	0.467 ± 0.006
Sentetik (%60)	VE=product / VEYA=godel	0.613 ± 0.038	0.466 ± 0.006

Tablo 2. K1 (μ = Q, zaman/süre kapalı). Kaynak: results/tables/k1_summary.csv.



Şekil 4. K1: Gödel'e göre eşleştirilmiş fark.

FrcSub'da operatörler pratikte aynıdır (%60'ta F1 0.849 / 0.848 / 0.847; Gödel'e göre fark −0.0007 ... −0.0019, std 0.0014-0.0032; çoğu hata çubuğu sıfırı keser). Sentetik veride sıralama Gödel > çarpım > Łukasiewicz'dir (F1 farkları −0.002 ... −0.008, RMSE farkları +0.0005 ... +0.0015), ancak **veri Gödel ile üretildiği için bu beklenen bir sonuçtur** ve operatörlerin genel üstünlüğünü göstermez. Pratik etki küçüktür (F1 ≤ 0.008).

Döngüsellik kontrolü. Aynı 5 ayar, bu kez veriyi *çarpım* ailesiyle üreterek tekrarlandı (VE: $\Pi\, \tilde{a}_k$, VEYA: $1 - \Pi(1 - \tilde{a}_k)$; diğer her şey aynı; %60, 10 seed):

Ayar (veri: ÇARPIMLA üretilmiş)	F1	RMSE	AUC
VE=godel / VEYA=godel	0.612 ± 0.042	0.442 ± 0.009	0.7556
VE=godel / VEYA=lukasiewicz	0.609 ± 0.040	0.443 ± 0.009	0.7549
VE=godel / VEYA=product	0.612 ± 0.041	0.442 ± 0.009	0.7556
VE=lukasiewicz / VEYA=godel	0.618 ± 0.039	0.443 ± 0.009	0.7543
VE=product / VEYA=godel	0.615 ± 0.040	0.442 ± 0.009	0.7557

Tablo 3a. K1, çarpım operatörüyle üretilmiş sentetik veri. Kaynak: results/tables/k1_product_summary.csv. Not: bu veri Gödel verisinden zorlukça farklıdır (genel doğru oranı seed 0'da 0.40, Gödel'de 0.46), bu yüzden mutlak sayılar iki tablo arasında kıyaslanmaz; yalnızca ayarlar arası sıralama kıyaslanır.

Gödel verisindeki "Gödel > çarpım > Łukasiewicz" sıralaması burada **yeniden çıkmadı**: VE=Łukasiewicz en yüksek F1'e sahip (Gödel/Gödel'e göre +0.0060, 10/10 seed), ancak RMSE (+0.0005) ve AUC'de (−0.0013) 10 seed'in hiçbirinde daha iyi değildir, yani bu F1 kazancı yine eşik/kalibrasyon etkisine benziyor. VE=çarpım F1 +0.0028 (8/10), RMSE −0.0001 (8/10) ve AUC +0.0002 (6/10) ile hafif önde; VEYA=çarpım Gödel ile ayırt edilemez. Tüm farklar çok küçüktür (RMSE ≤ 0.0005, AUC ≤ 0.0013). Sonuç: operatör sıralaması üretecin kendisine bağlıdır (Gödel verisinde Gödel öne çıkarken çarpım verisinde çıkmadı) ve gerçek veride de fark yoktur; bu, K1'in "operatör seçimi etkisiz" sonucunu ve döngüsellik uyarısını destekler. Çarpım verisinde çarpım modelinin *belirgin* kazanmaması ayrıca, modelin parametrelerinin (özellikle α, β, μ) zayıf belirlenmiş olmasıyla da uyumludur (Bölüm 8.2).

8.4 K2: faktör ablation'ı ve negatif kontrol (sentetik, %60, 10 seed)

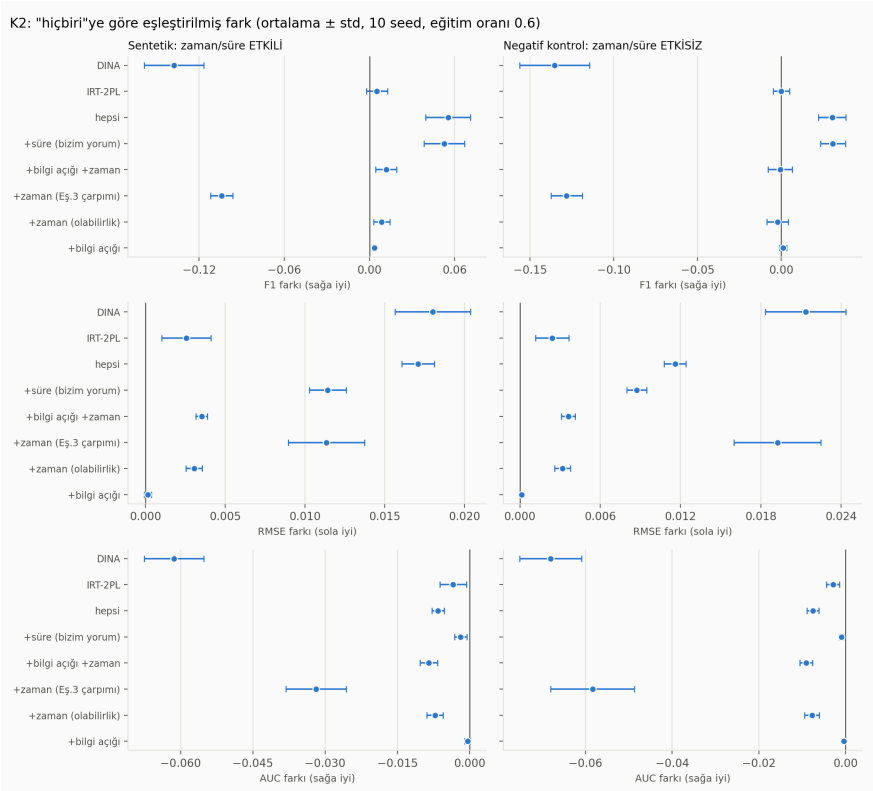
Zaman/süre etkili veri:

Model	F1	AUC	RMSE	ort. tahmin	gerçek oran
hiçbiri	0.618 ± 0.037	0.706 ± 0.018	0.465 ± 0.006	0.481	0.481
+bilgi açığı	0.621 ± 0.037	0.706 ± 0.018	0.466 ± 0.006	0.482	0.481
+zaman (olabilirlik)	0.627 ± 0.037	0.699 ± 0.018	0.469 ± 0.006	0.494	0.481
+zaman (Eş.3 çarpımı)	0.514 ± 0.042	0.674 ± 0.017	0.477 ± 0.005	0.454	0.481
+bilgi açığı +zaman	0.630 ± 0.038	0.698 ± 0.019	0.469 ± 0.006	0.497	0.481
+süre (bizim yorum)	0.671 ± 0.024	0.704 ± 0.018	0.477 ± 0.006	0.580	0.481
hepsi	0.673 ± 0.022	0.700 ± 0.018	0.483 ± 0.006	0.597	0.481
IRT-2PL	0.623 ± 0.034	0.703 ± 0.019	0.468 ± 0.006	0.482	0.481
DINA	0.480 ± 0.051	0.645 ± 0.020	0.483 ± 0.005	0.456	0.481

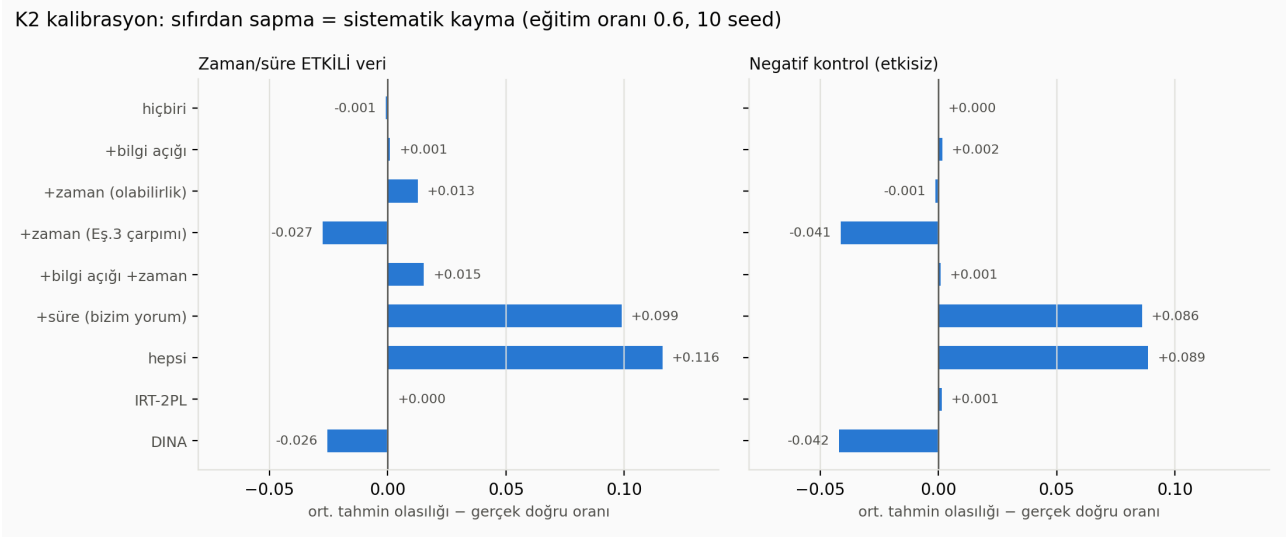
Negatif kontrol (zaman/süre etkisiz):

Model	F1	AUC	RMSE	ort. tahmin	gerçek oran
hiçbiri	0.678 ± 0.029	0.713 ± 0.017	0.463 ± 0.006	0.526	0.526
+bilgi açığı	0.679 ± 0.029	0.713 ± 0.016	0.463 ± 0.006	0.528	0.526
+zaman (olabilirlik)	0.676 ± 0.032	0.705 ± 0.017	0.466 ± 0.006	0.525	0.526
+zaman (Eş.3 çarpımı)	0.550 ± 0.037	0.655 ± 0.018	0.482 ± 0.004	0.485	0.526
+bilgi açığı +zaman	0.677 ± 0.033	0.704 ± 0.017	0.467 ± 0.006	0.527	0.526
+süre (bizim yorum)	0.709 ± 0.022	0.712 ± 0.016	0.472 ± 0.006	0.612	0.526
hepsi	0.708 ± 0.022	0.706 ± 0.017	0.475 ± 0.006	0.615	0.526
IRT-2PL	0.678 ± 0.028	0.710 ± 0.017	0.465 ± 0.006	0.528	0.526
DINA	0.542 ± 0.043	0.645 ± 0.019	0.484 ± 0.004	0.484	0.526

Tablo 3. K2. "ort. tahmin" modelin ortalama doğru olasılığı, "gerçek oran" testteki doğru oranı. Kaynak: results/tables/k2_summary.csv.



Şekil 5. K2: "hiçbiri"ye göre eşleştirilmiş fark (F1, RMSE, AUC; solda etkili veri, sağda negatif kontrol).



Şekil 6. K2 kalibrasyon kayması: ortalama tahmin olasılığı − gerçek doğru oranı.

Ana bulgu. "+süre" F1'i +0.053 artırır (0.618 → 0.671), ancak negatif kontrolde de +0.031 artırır (0.678 → 0.709); süre bilgisi cevaptan bağımsızken de F1 yükselmektedir. Neden: ωC yalnızca doğru cevaplara bonus verir; olabilirlik doğru cevaplara daha fazla ağırlık verince model "doğru" demeye kayar (ortalama tahmin 0.481 → 0.580, gerçek oran 0.481), doğru sınıf pozitif olduğu için Recall (0.59 → 0.79 civarı) ve F1 artar, PRE ve RMSE kötüleşir. Şekil 6 bu kaymayı gösterir. **Hiçbir faktör AUC'yi artırmadı** ("hiçbiri"ye göre AUC farkı: bilgi açığı −0.0005, zaman −0.0072, Eş.3 −0.0319, bilgi açığı+zaman −0.0085, süre −0.0019, hepsi −0.0066). Dereceli μ (+bilgi açığı) yalnızca +0.003 F1 verdi; AUC ve RMSE değişmedi. Makalenin yazımına en yakın okumamız (Eş.3 çarpımı) F1'i −0.104 düşürdü ve en kötü yakınsayan ayar oldu. DINA her koşulda en kötüdür (F1 −0.138, AUC −0.061), bu makaledeki DINA < FuzzyCDF eğilimiyle uyumludur. IRT-2PL, MFCD varyantlarıyla aynı düzeyde ya da daha iyi RMSE'ye sahiptir.

8.5 E4: eğitim süresi ve baseline - geliştirilen karşılaştırması

Model	FrcSub (sn)	Sentetik (sn)
IRT-2PL	0.03 (0.00)	0.11 (0.08)
DINA	1.33 (0.06)	5.86 (0.11)
FuzzyCDF-orig	6.21 (0.02)	54.35 (1.99)
MFCD-core	7.11 (0.04)	64.82 (1.73)
MFCD hepsi (süre+zaman+μ)	–	64.33 (1.66)

Tablo 4. Ortalama süre (std); tek işlem, tek zincir, %60, 3 seed; Apple M4 Pro. Kaynak: results/tables/e4_sure_summary.csv.

Ölçüt (FrcSub, %60)	Baseline: FuzzyCDF-orig	Geliştirilen: MFCD-core	Değişim
F1	0.849	0.845	-0.004
RMSE	0.352	0.352	+0.000
MAE	0.252	0.254	+0.002
Süre (sn, tek zincir)	6.21	7.11	+0.90

Tablo 5. Yönergenin 6.2 biçiminde özet (FrcSub, %60; süre E4'ten, tek zincir). Değişim = geliştirilen − baseline. Geliştirilen yöntem daha iyi değildir.

9. Discussion

Neden makale eğilimi yeniden üretilemedi? Dört olası neden var, hiçbiri bu çalışmada ayrıca test edilmemiştir: (1) FrcSub'da zaman, süre ve öznel soru yoktur, yani makalenin eklemelerinin çoğu devre dışıdır; (2) ikili Q'da bilgi açığı min'e indiğinden dereceli μ ek bilgi taşımaz, yalnızca serbestlik ekler ve posterior çok modlu olur; (3) makalenin büyük sıçraması MAKT'tan gelebilir; (4) ağırlık uygulaması makalede belirsizdir ve bizim iki yorumumuz makalenin yöntemi olmayabilir.

Metrik seçimi. F1, PRE ve Recall tek başına eşik ve yanlılık yüzünden yanıltabilir: yalnızca doğru cevapları ağırlıklandıran bir yöntem tahmini "doğru"ya kaydırarak F1'i yapay biçimde yükseltir. Negatif kontrol bu durumu yakalamıştır; bu nedenle AUC, RMSE ve kalibrasyon birlikte raporlanmalıdır. Aynı uyarı makale karşılaştırmalarını okurken de geçerlidir (Tablo 4'teki PRE/Recall/F1 tutarsızlıkları).

Operatör seçimi. Gerçek veride operatör ailesi pratikte fark etmemiştir. Olası (test edilmemiş) sezgi: Łukasiewicz VE'si birkaç beceri gerektiren sorularda η'yı sık sık tam 0'a indirir; bu bölgede olasılık sabit (≈ guess) kalır ve öğrenciler ayırt edilemez. Gödel'de yalnızca en zayıf beceri belirleyicidir.

Olumsuz sonucun değeri. Yönerge performans artışını zorunlu kılmaz. Burada değerli bulgu, makalenin eklemelerinin kontrollü bir ortamda sıralama başarısını artırmadığı ve F1'deki görünür kazancın bir kalibrasyon yapaylığı olduğudur. Bu, "makale yanlıştır" demek değildir: çalışmamız makalenin verisini, MAKT'ını ve kesin ağırlık formülünü içermez.

10. Limitations

- **Kapsam:** MAKT yoktur; makalenin verisi kapalıdır, yalnızca FrcSub (ikili, objektif, zaman/süre yok) kullanılabilmiştir.
- **Kendi yorumlarımız:** zaman/süre ağırlıklarının olabilirlik ağırlığı olarak uygulanması, Eş. 7 normalizasyonu ve $\lambda = 1$, önseller, adım boyları ve DINA gerçekleştirmesi bizimdir; makalenin birebir yöntemi olmayabilir.
- **Sentetik veri:** Gödel ve zaman/süre etkileriyle üretildiği için döngüseldir; negatif kontrol bu riski azaltır ama gerçek veri yerine geçmez. K1/K2 yalnızca %60 eğitim oranında koşulmuştur; "+süre" için yalnızca $\lambda = 1$ denenmiştir.
- **MCMC:** FrcSub'da MFCD-core çok modludur (3 başlangıç yetmeyebilir); sentetikte bireysel α, β, μ, s, g zayıf belirlenmiştir ve yorumlanmaz. K2 tek zincirli MH ile koşulmuştur.
- **İstatistik:** 10 seed; küçük farklar (örn. MFCD-core − FuzzyCDF-orig, F1 ≈ −0.003) seed gürültüsüne yakındır. Çoklu karşılaştırma düzeltmesi uygulanmamıştır.
- **Süre:** E1-K2'deki paralel koşu süreleri kıyaslanamaz; süre karşılaştırması yalnızca E4'tendir (tek makine, 3 seed).

11. Conclusion

Makalenin bulanık çekirdeği (sigmoid üyelik, t-norm/t-conorm, bilgi açığı, slip/guess, MH) sıfırdan gerçekleştirilmiş, test edilmiş ve FrcSub'da baseline'larla karşılaştırılmıştır. Çekirdek IRT-2PL ve DINA'dan RMSE/F1'de iyidir, ancak FuzzyCDF-orig'i geçmemiştir; makalenin üç eklemesinin yararı kontrollü deneylerimizde gösterilememiştir. K1'de operatör ailesi gerçek veride etkisizdir; K2'de F1 kazancının kalibrasyon yapaylığı olduğu negatif kontrol ve AUC ile gösterilmiştir. Gelecek çalışma: süreyi cevabın olasılığına bağlayan bir model; tüm eğitim oranlarında K1/K2; makalenin ağırlık formüllerinin yazarlarla netleştirilmesi; MAKT'ın ayrıştırılmış etkisi.

Generative AI Usage Disclosure

Bu projede üretken yapay zekâ aracı **Claude Code** (Anthropic) kullanılmıştır: kodun yazılması ve hata ayıklama, deney tasarımının tartışılması, bulanık mantık kavramlarının açıklanması, istatistiksel tanı yöntemlerinin (R-hat, eşleştirilmiş fark) önerilmesi, web aramasıyla literatür ve künye doğrulamasına yardım, README ve rapor metnini düzenleme. Kullanım ayrıntıları `docs/ai_usage_log.md` dosyasındadır. Rapordaki tüm deney sayıları, tablolar ve grafikler repodaki betiklerin çıktısıdır (`report/build_report.py` tabloları CSV dosyalarından üretir). Kaynaklar yayıncı/indeks sayfalarından tek tek doğrulanmıştır; makalenin kendi kaynakçasından kopyalama yapılmamıştır. Üretilen kodun ve metnin doğruluğunun kontrolü yazarın sorumluluğundadır.

References

1. Y. Zhang and Y. Wang, "A personalized recommendation algorithm for English exercises incorporating fuzzy cognitive models and multiple attention mechanisms," *Sci. Rep.*, vol. 15, Art. no. 11531, 2025, doi: 10.1038/s41598-025-96489-3.
2. R. Wu, Q. Liu, Y. Liu, E. Chen, Y. Su, Z. Chen, and G. Hu, "Cognitive modelling for predicting examinee performance," in *Proc. 24th Int. Joint Conf. Artif. Intell. (IJCAI)*, 2015, pp. 1017-1024.
3. Q. Liu, R. Wu, E. Chen, G. Xu, Y. Su, Z. Chen, and G. Hu, "Fuzzy cognitive diagnosis for modelling examinee performance," *ACM Trans. Intell. Syst. Technol.*, vol. 9, no. 4, Art. no. 48, pp. 48:1-48:26, 2018, doi: 10.1145/3168361.
4. B. W. Junker and K. Sijtsma, "Cognitive assessment models with few assumptions, and connections with nonparametric item response theory," *Appl. Psychol. Meas.*, vol. 25, no. 3, pp. 258-272, 2001, doi: 10.1177/01466210122032064.
5. C. Piech *et al.*, "Deep knowledge tracing," in *Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 28, 2015, pp. 505-513.
6. J. Zhang, X. Shi, I. King, and D.-Y. Yeung, "Dynamic key-value memory networks for knowledge tracing," in *Proc. 26th Int. Conf. World Wide Web (WWW)*, 2017, pp. 765-774, doi: 10.1145/3038912.3052580.
7. F. Wang, Q. Liu, E. Chen, *et al.*, "Neural cognitive diagnosis for intelligent education systems," in *Proc. AAAI Conf. Artif. Intell.*, vol. 34, no. 4, 2020, pp. 6153-6161, doi: 10.1609/aaai.v34i04.6080.
8. F. Wang, W. Gao, Q. Liu, J. Li, G. Zhao, Z. Zhang, Z. Huang, M. Zhu, S. Wang, W. Tong, and E. Chen, "A survey of models for cognitive diagnosis: New developments and future directions," arXiv:2407.05458, 2024 (preprint).
9. L. A. Zadeh, "Fuzzy sets," *Inf. Control*, vol. 8, no. 3, pp. 338-353, 1965, doi: 10.1016/S0019-9958(65)90241-X.
10. W. K. Hastings, "Monte Carlo sampling methods using Markov chains and their applications," *Biometrika*, vol. 57, no. 1, pp. 97-109, 1970, doi: 10.1093/biomet/57.1.97.
11. A. Gelman and D. B. Rubin, "Inference from iterative simulation using multiple sequences," *Stat. Sci.*, vol. 7, no. 4, pp. 457-472, 1992, doi: 10.1214/ss/1177011136.